

E2E обучение

Nanogpt: [ИСХОДНЫЙ КОД](#)

Hidden size: 272

Attention heads: 4

Head dimension: 68

MLP dimension: 1088

Context: 256 tokens

Vocabulary: 16 384

Parameters: 19.68 млн

Batch: 64

Gradient accumulation: 4

Effective batch: 65 536 tokens


Data: **WikiText-103(raw text)** 100M tokens

Tokenization: byte-level BPE


Validation: 60 individual articles

Logging: comet: team-rl-exp/local-learning

val/loss VS step






val/ppi VS step




E2E. Linerity, KL by layers

Linear CKA between residual streams



Реализация sid блоков в трансформере



$$CE_i = CE(y, \text{softmax}(\text{readout}(h_i)))$$

$$D_{KL}(q || p) = \sum_v q_v \cdot \log(q_v / p_v)$$

$$L_{\text{block}} = CE + \lambda \cdot KL$$


λ – увеличивается от 0 до 0.5 за первые 10 % данных. Так как на первых шагах распределения в соседних блоках может сильно различаться.

Различные варианты работы с backbone


- При обучении без замороженного backbone , только последовательности sid блоков – обучение не сходится, конечное ppl около 1000.
- Использование первых k замороженных предобученных слоев из e2e обучения.
- Использование первых k предобученных слоев из e2e обучения.

Сравнение при различных k (замороженный)

K = 3




K = 6






Сравнение при различных k

$K = 3$




$K = 6$




Сравнение при различных k

K = 3





K = 6



k	Слоёв backbone	Верхних блоков	Источник backbone	Финальный ppl	Улучшение от глубины
3	3	9	checkpoint_50pct	111.3	+6.9%
6	6	6	checkpoint_50pct	107.16	+5.1%
6	6	6	checkpoint_100pct (сильнее старт)	88.06 (лучший абс. ppl в SID-F)	+4.58%



Добучение backbone с sid блоками



Полное обучение с нуля sid блоков не сходится. PPL растёт.

Шраф за линейность

$$\mathcal{L}_i = \text{CE}(y, p_i) + \lambda_{\text{div}} \cdot \text{CKA}(\text{sg}(h_{i-1}), h_i),$$
$$\lambda_{\text{div}} = 1.0 = 1.0$$



Сравнение при различных размерах блоков

k	block-size	Блоков	Финальный ppl	Улучшение	Примечание
3	1	9	111.3	+6.9%	чистый (без абляций)
6	1	6	107.16 / 88.06	+5.1% / +4.58%	чистый (50pct / 100pct)
4	2	4	101.67	+3.82%	чистый

PPL

Эксперимент	Конфигурация	Финальная PPL	Условия
E2E baseline	12 слоёв, полный backprop	105.68	100 млн токенов
SID-F	$k=3$, 9 верхних блоков	111.30	frozen backbone, local CE
SID-F	$k=6$, backbone из E2E 50%	107.16	frozen backbone, local CE
SID-F	$k=6$, backbone из E2E 100%	88.06	frozen backbone, local CE
SID-F	$k=4$, block-size=2	101.67	frozen backbone, крупные блоки
SID-P	$k=6$, consistency KL	84.37	backbone продолжает обучаться

Разные варианты работы с readout

- Readout обучается каждым sid блоком
- Readout обновляется только последним блоком
- Readout заморожен
- Лучше всего себя показывает вариант, где readout обучается поверх самого верного распределения. Замороженный вариант, обучен под e2e, что не соответствует фактическому распределению после sid блоков.


Режим readout	Block-size	val_pp1 (последний блок)	Δ к базовому
Обучается каждым блоком	1	107.16	база
Обновляется только последним блоком	2	101.64	-5.2%
Заморожен полностью	1	136.58	+27.5%

Последовательный вариант

- Составляющая лосса KL в sid блоках, сравнивает результат
- При увеличении числа слоев в блоке, наблюдается результат отличный от SID-f

$$\mathcal{L}_i = \begin{cases} \text{CE}(y, \text{softmax}(z_i)) & p_{\text{target}} < 0.2 \text{ (correct)} \\ 0.5 \cdot \text{CE}(y, \text{softmax}(z_i)) & 0.2 \leq p_{\text{target}} < 0.8 \text{ (refine)} \\ \text{KL}(\text{sg}(p_{\text{old}}) \parallel \text{softmax}(z_i)) & p_{\text{target}} \geq 0.8 \text{ (preserve)} \end{cases}$$

Конфигурация	Слоёв в блоке	Число stage'ов	Backbone-pp1 (0 stage'ов)	Финальный pp1	Прирост
k=6, block-size=1	1	6	302.57	202.47	+33.1%
k=6, block-size=2	2	3	302.57	193.05	+36.2%
k=0 (без backbone), block-size=3	3	4	5512.31	675.03	+87.8%





Sid блоки с разными горизонтами предсказания

Блок	Слои	Горизонт s_i
0	4–5	1
1	6–7	2
2	8–9	4
3	10–11	8

- При $s = 1$, идет обучение обычным CE, next token
- Для более дальних горизонтов, обучаются вспомогательные головы, которые адаптируют подаваемое представление под более дальний горизонт перед readout.


Блок (горизонт)	val ppl (next-token)
4–5 ($s = 1$)	105.49
6–7 ($s = 2$)	102.48
8–9 ($s = 4$)	101.70
10–11 ($s = 8$, последний)	101.43

Результаты по слоям




Бустинг вариант

$$\begin{aligned}z_i &= \text{sg}(z_{i-1}) + \alpha_i \cdot \text{readout}(h_i), \\z_0 &= \text{readout}(h_0), \\h_i &= F_i(\text{sg}(h_{i-1})) \\ \mathcal{L}_i &= \text{CE}(y, \text{softmax}(z_i)),\end{aligned}$$



Метод	val_ppl (итог)	Δ к E2E	Прирост от глубины	Backbone
E2E-baseline	105.68	0%	—	сквозной, единый forward
SID-P-Boost (обучаемый α, k=6)	87.63	−17.1%	+4.6%	учится (тёплый старт из E2)
SID-F (k=6, backbone из checkpoint_100pct)	88.06	−16.7%	+4.58%	заморожен, сильный старт
SID-F (k=4/bs=2, freeze-readout except-last)	101.64	−3.8%	—	заморожен
SID-Horizons (k=4/bs=2)	101.43	−4.0%	−3.85%	заморожен
SID-F (k=3, backbone из checkpoint_50pct)	111.3	+5.3%	+6.9%	заморожен
SID-P-Boost без обучаемого α (v1)	273	+158%	−120% (растёт с глубиной)	учится



Вариант с разделением словаря между блоками

Развитие идеи бустинга, в самом начале мы случайно инициализируем случайные окна в словаре для каждого блока и каждый блок выдает поправки только по этим токенам. Сначала блок сжимает своё внутреннее представление в вектор размерности 256, затем этот маленький вектор умножается на фиксированную матрицу трафарет, которая раскидывает эти значения по словарю только на позиции которые были инициализированы для конкретно этого блока (~1600 позиций словаря (10% от 16384).

